

RAG 应用开发入门（典例版）

—— PDF 格式典例：正式文档排版，用于 anydoc 转换对比

RAG 是什么

检索增强生成（Retrieval-Augmented

Generation）：回答前先从你的私有资料里查资料，把查到的原文塞进提问，再让模型基于资料回答。类比：开卷考试——裸问答是闭卷，模型只会背书上的还可能记错；RAG 是开卷，带着笔记进场翻到相关段落再答题。

为什么要先查资料

模型的记忆是训练时写死的，有两个硬伤：不知道你的事（你的笔记、公司文档模型从没见过）；会一本正经地胡说（记忆模糊时倾向编一个听起来合理的答案，这就是幻觉）。RAG 的思路是不改造模型，而是在提问时喂它需要的那几页资料——模型不擅长记忆，但擅长照着资料说话。

切块：两种切法

模型每次能看的文字有限，先把文档切成小块，提问时只挑相关的几块。窗口切：固定 500 字一块、步长 450，重叠 50 字防止一句话被从中间切断。标题结构切：按文档标题分节，一个标题一块，标题是天然的语义边界。项目用两级策略：标题分节为主，某节超过 500 字在节内再窗口切；无标题文档退化为纯窗口切。

向量化：文字变数字

电脑不懂意思但懂数字。嵌入模型把一段文字映射成一串数字（向量），规则是意思相近的文字向量方向也相近：猫和猫咪的向量挨得很近，猫和汽车的向量离得很远。向量是一串数字，数字本身没意义，方向才表达语义。

检索：余弦相似度

提问来了：先把问题也变成向量，然后和库里每一块的向量比方向像不像，取最像的 top-k 块。数学上就是余弦相似度：点积衡量方向一致性，除以模长抵消长度影响，范围负一到一，越大越像。为什么用余弦不用距离？向量长度受文本长度影响，余弦只看方向更公平。

最佳输入格式

向量化用什么格式输入最佳？Markdown。理由：结构完整，标题、表格、代码块都是切块与检索的强信号；纯文本会把这些结构抹平，PDF 表格转纯文本后语义粘连。让资料保持 Markdown 进管道，检索命中率和答案可追溯性都更好。

路线对比

【微调】成本：高：要数据、要算力、要调参；见效：慢，像重新训练一次

【蒸馏】成本：高：需要大模型老师 + 大量标注；见效：慢，接近研发投入

【RAG】成本：低：代码 + 本地模型即可；见效：快：上传文档就能用，效果立竿见影

Prompt 模板

资料1: ...

资料2: ...

问题: ...

请仅依据以上资料回答，不要编造资料外的内容。