

典例文档集 · 设计说明 (bench_corpus)

用途：横向对比「文档格式 → anydoc → Markdown → 切块 → 向量化检索」的质量差异。

设计原则：内容同源，仅格式变排版

六类文档都围绕同一套 RAG 知识点（六节），只按格式特性排版——word 正式排版、excel 表格化、ppt 标题要点页、epub 章节图文、md 原生、pdf 正式文档、pdf 扫描版（文本版的光栅化图片件）。这样横向对比时「内容变量」被控住，测出的差异就是格式本身的影响。

典例清单

文件	类型	说明
01_word_rag入门.docx	Word	正式排版：Heading + 表格 + 代码块
02_excel_rag知识点.xlsx	Excel	表格化：知识点速查 + 路线对比两张表
03_ppt_rag入门.pptx	PPT	封面 + 6 内容页 + 1 流程图页
04_epub_rag图文.epub	EPUB	3 章节 + 内嵌流程示意图
05_md_rag入门.md	Markdown	原生基准（对照）
06_pdf_rag入门.pdf	PDF	文本型正式文档
07_pdf扫描版_rag入门.pdf	PDF	扫描型（图片型，06 的光栅化）

六节知识点与判定锚句

节	锚句
RAG 是什么	开卷考试
为什么要先查资料	一本正经地胡说
切块：两种切法	标题结构切

节	锚句
向量化：文字变数字	方向才表达语义
检索：余弦相似度	余弦相似度
最佳输入格式	Markdown

测试流程（建议）

1. anydoc 把每份典例转成 Markdown（记录转换告警/丢失项）
2. 转换结果用 chunk_markdown 切块，每类文档得到若干块
3. 六题提问（锚句即答案所在块），逐类文档测 top-3 命中率
4. 记录：块数、总字数、命中率、转换耗时 → 产出对比表

预期观察点

- excel 表格转 md 后是否保留表头/行结构，还是粘连成一坨文本
- ppt 要点页转 md 后标题层级是否保留
- epub 图文混排：图片是否丢失、章节结构是否保留
- pdf 表格/代码块是否被截断或粘连
- md 作为基准：原生结构应保持最高命中率（若否，说明 anydoc 或切块有问题）

生成方式（可复现）

```
uv run --with python-docx --with openpyxl --with python-pptx --with fpdf2 --with pillow
python -m scripts.make_bench_corpus
```

依赖全部按需注入，不写进 pyproject（典例生成是实验工具，不是项目运行时依赖）。

测试边界说明

横向对比与挡位推荐基于 x64 Windows 实测（CPU 版 / Vulkan 核显版 / CUDA 独显版），未测试 ROCm（AMD 独显 Linux）与 arm 架构 CPU。

