

RAG 手写全链路学习笔记 #01：模型服务启动与向量化输入

2026-10-01 · RAG_HandProj 工程 M2 前置 · 学习者视角

目录

- 1. 环境事实
- 2. 模型服务启动
 - 2.1 两个服务
 - 2.2 参数含义
 - 2.3 启动输出解读
- 3. 验证：向量维度
- 4. 向量化最佳输入格式
 - 4.1 结论
 - 4.2 三层理由
 - 4.3 管线形态
- 5. 横向对比候选
- 6. 踩坑与安全

1. 环境事实

本机为 NVIDIA GeForce RTX 4090 D，显存 24GB（实测空闲 21.7GB），llama.cpp 使用 CUDA 13.4 版本，位于 `D:\software\llama-b11159-bin-win-cuda-13.4-x64`。显存充足，嵌入模型与聊天模型可同时驻留。

角色	模型	量化	大小
嵌入 8B（主力）	Qwen3-Embedding-8B	Q5_K_M	5.2 GB
嵌入 4B（候选）	Qwen3-Embedding-4B	Q5_K_M	2.8 GB

角色	模型	量化	大小
聊天 4B	Qwen3.5-4B	Q5_K_M	3.0 GB
嵌入 12B（横向对比）	KaLM-Embedding-Gemma3-12B	i1 Q5_K_M	8.1 GB

模型文件统一位于 `D:\llamacpp_models` 目录下，按厂商与系列分子目录存放。

2. 模型服务启动

2.1 两个服务

嵌入服务监听 8081 端口，聊天服务监听 8080 端口。二者是两条独立的 llama-server 进程，分别加载不同模型，互不干扰。

```
llama-server.exe -m D:\llamacpp_models\qwen3-embed\Qwen3-Embedding-8B-Q5_K_M.gguf --embedding --pooling last -c 8192 -b 8192 -ub 8192 --host 127.0.0.1 --port 8081
```

```
llama-server.exe -m D:\llamacpp_models\qwen3.5\Qwen3.5-4B-Q5_K_M.gguf -c 8192 -b 8192 -ub 8192 --host 127.0.0.1 --port 8080
```

2.2 参数含义

参数	含义	类比
<code>-m</code>	模型文件路径	烘焙的原料
<code>--embedding</code>	嵌入模式，只输出向量不做对话	文字变数字的编码器
<code>--pooling last</code>	取最后一层隐藏状态做句子向量	一串数字里挑最有用那个
<code>-c 8192</code>	上下文窗口（token 数）	一次能记住多长输入
<code>-b / -ub</code>	batch / ubatch 大小	一次处理多少块
<code>--host 127.0.0.1</code>	只监听本机	不上公网，防偷窥
<code>--port</code>	服务端端口	门牌号

2.3 启动输出解读

出现 `model loaded` 与 `listening on http://127.0.0.1:8081` 即表示服务就绪。聊天服务启动时的 `unused tensor blk.32.*` 警告来自 MTP (Multi-Token Prediction) 模型的多余预测层, chat 模式用不到这些层, llama.cpp 自动忽略, 属于正常现象, 不是错误。

3. 验证：向量维度

用一段三行脚本调用嵌入服务, 确认模型输出维度。Qwen3-Embedding-8B 实测返回 **4096 维**向量 (4B 版本为 2560 维, KaLM 12B 待实测)。维度是存储层建表的关键参数——chunks 表要按维度存向量, 换模型必须重建知识库。

```
POST http://127.0.0.1:8081/v1/embeddings {"model": "qwen3-embed", "input": "你好世界"}
→ dim: 4096   head: [0.0246, -0.0055, 0.0031, ...]
```

4. 向量化最佳输入格式

4.1 结论

保留标题结构的轻量 Markdown 是最佳输入格式。 PDF、Word 等二进制格式对 embedding 模型不可见, 模型只能看到解析后的文字流。

4.2 三层理由

1. **tokenizer 视角**: embedding 模型按 token 读取文本, 格式问题的本质是“希望模型从哪些字符里提取语义”。
2. **标题是语义结构**: Markdown 的标题层级是语义边界, 与手写 RAG 的标题切块策略 (按【】分节) 完美咬合。切块是检索质量的第一道闸门, 标题把这道闸门留给了 Markdown。
3. **管线归一化**: 任何文档经 anydoc 统一转为 Markdown 后, 切块与向量化只需处理一种格式, 加新格式只动转换层——这是把异构入参收敛到一个入口的重构思想。

4.3 管线形态

PDF / Word / PPT / 图片 —► anydoc 归一化 —► Markdown —► 标题切块 —► 向量化

实操细节: 装饰性标记 (超长链接、代码注释) 会稀释向量但影响很小; 真正要保留的是标题层级。500 字切块约 600 至 800 token, 8B 的 8192 token 上下文绰绰有余。

5. 横向对比候选

KaLM-Embedding-Gemma3-12B 已就位 (i1 量化, Q4_K_M 6.9GB / Q5_K_M 8.1GB) , 可作为与 Qwen3-Embedding-8B 的检索命中率对照实验。其输出维度待起服务后实测确认, 横向对比的判据沿用余弦相似度 top-k 命中率, 不凭感觉。

6. 踩坑与安全

1. **MTP 模型的 unused tensor 警告不是错误**, 忽略即可。
2. **CORS 全开警告**: 本机调试无碍, 但上公网前必须加 `--api-key` , 否则任何能访问端口的人都能调用模型。
3. **--pooling last 必须带**: Qwen3-Embedding 官方要求 last 池化, 缺失会导致向量化出错; 编码模型与聊天模型的启动方式不同, 嵌入模式必须同时加 `--embedding` 与池化参数。