

RAG 演示台 · 快速上手

本文面向想直接体验的人：不用懂代码，照着做就能让一个本地 AI 问答系统跑起来 —— **你的文档它来答，答案还能点开看依据。**

一、你需要准备什么

东西	说明
Windows 电脑	有 NVIDIA 显卡体验最佳 (llama.cpp CUDA 版) ； 无显卡也能跑，慢一些
Python 3.12 + uv	环境管理（不会装的看下方「常见问题」）
llama.cpp	模型推理程序，解压即可用
模型文件（GGUF）	两个： 嵌入模型 （负责把文字变成向量） + 对话模型 （负责生成回答）

模型文件放哪个目录都行，下面命令里的路径按你的实际情况改。

二、启动两个模型服务（最关键的一步）

模型服务是系统的 "发动机"，要先点着。打开两个 PowerShell 窗口分别运行：

服务 1：嵌入模型（端口 8081）

```
llama-server.exe -m D:\llamacpp_models\qwen3-embed\Qwen3-Embedding-8B-Q5_K_M.gguf --embedding --pooling last -c 8192 -b 8192 -ub 8192 --host 127.0.0.1 --port 8081
```

看到 `listening on http://127.0.0.1:8081` 即启动成功。

两个参数不能省：

- `--embedding`：让模型以 "编码模式" 运行（输出向量而不是聊天）

- `--pooling last`：取最后一层隐藏状态作为整句话的向量（Qwen 嵌入模型的官方要求）

服务 2：对话模型（端口 8080）

```
llama-server.exe -m D:\llamacpp_models\qwen3.5\Qwen3.5-4B-Q5_K_M.gguf -c 8192 -b 8192 -ub 8192 --host 127.0.0.1 --port 8080
```

注意：对话模型不带 `--embedding` 参数。

三、启动演示台

在项目目录（`RAG_HandProj`）打开 PowerShell：

```
uv sync
uv run uvicorn main:app --host 127.0.0.1 --port 8000
```

浏览器打开 <http://127.0.0.1:8000>，看到「RAG 演示台」页面即成功。

四、开箱体验

1. **先装知识库**：演示台右侧「知识库」区点「选择文件」→「上传入库」，支持 txt/md/markdown + doc/docx/xlsx/pptx/pdf/epub/rtf 等 15+ 种常见格式（anydoc 统一转 Markdown 入库；内置示例文档无需手动操作）；已入库的文档可点「删除」移除
2. **提问**：输入问题回车，模型会基于知识库回答
3. **看依据**：答案下方「参考源」列表点开，能看到模型依据的原文块——每个知识点都能追到出处
4. **管理知识库**：演示页可直接上传 / 删除；需要批量或自动化时用接口 `POST /library`、`DELETE /library/{文档名}`（Swagger 或命令行）

五、常见问题

Q：提问报「服务不可用 /connection refused」

A：两个模型服务没起来或端口不对。检查 8080/8081 窗口是否还在运行，`Test-NetConnection 127.0.0.1 -Port 8081` 看是否通。

Q: 换了嵌入模型后, 检索结果不对

A: 不同模型输出的向量维度不同 (8B=4096, 4B=2560) , 换模型后必须重建知识库:

```
uv run python -m scripts.build_kb "docs\RAG学习笔记01-模型服务与向量化输入.md" --reset
```

Q: 上传文件报 400

A: 分两种情况: ① 文件本身有问题——扫描型 PDF (纯图片页) 暂不支持、文件损坏/加密、内容为空; ② 文件没问题但格式不支持——常见格式基本都支持 (txt/md/markdown + doc/docx/xlsx/pptx/pdf/epub/rtf 等 15+ 种, anydoc 统一转 Markdown 入库) , 纯文本还会自动识别 UTF-8 / GBK / UTF-16 编码。报 400 时看错误提示, 按提示处理即可。

Q: 没有显卡能跑吗

A: 能。llama.cpp 有 CPU 版, 速度慢但可用; 对话模型建议 4B 量化版。

Q: llama.cpp 升级后, 启动命令不对了怎么办

A: llama.cpp 不同版本的启动参数可能有变化, **以你下载的那个版本为准**。旧命令失效时, 把旧命令 (作用: 加载模型、开嵌入模式/池化、设端口) 发给 AI, 让它按你的新版本生成新命令; **对不对以能不能跑起来为准**——命令行出现 `listening on http://...` 即成功。

六、给开发者

- 跑测试 (不需要模型) : `uv run pytest -q`
- 接口文档: 服务启动后打开 <http://127.0.0.1:8000/docs> (Swagger UI)
- 源码导览: 见 [源码导读.md](#) (进阶读代码) ; 想先学原理看 [RAG-Minimal](#) (156 行单文件教材)