

模型选型与横向对比报告（实测）

结论基于本机实测：Windows 11 / i9-14900K（24C/32T） / 64GB / RTX 4090 D 24GB， llama.cpp b11337（CUDA 12.4 / CPU / Vulkan 三后端已备）。未测 ROCm（AMD Linux 独显）与 arm CPU；相对排名与硬件无关，绝对速度按消费硬件折算。语料：源码导读.md / RAG学习笔记01 / 快速上手.md；库内题 12 + 库外题 3。

一、嵌入模型纯检索对比（9 模型 × 12 题）

口径：结构切块 → 全量向量化 → 余弦 top-3，锚句在 top-3 内即命中。只换嵌入模型。

排名	嵌入模型	池化方式	向量维度	体积	检索命中	单组耗时
1	Qwen3-Embedding-4B-Q4_K_M	last	2560	2.33GB	10/12	4.0s
2	Qwen3-Embedding-4B-Q5_K_M	last	2560	2.69GB	10/12	5.0s
3	Qwen3-Embedding-0.6B-Q8_0	last	1024	0.60GB	9/12	4.0s
4	harrier-oss-v1-0.6B-Q8_0	last	1024	0.60GB	9/12	4.0s
5	harrier-oss-v1-0.6B-BF16	last	1024	1.12GB	9/12	4.0s
6	Qwen3-Embedding-8B-Q5_K_M	last	4096	5.05GB	9/12	7.0s
7	bge-m3-q8_0	cls	1024	0.59GB	8/12	3.0s
8	KaLM-Embedding-Gemma3-12B-2511.Q5_K_M	last	3840	7.87GB	7/12	45.0s
9	KaLM-Embedding-Gemma3-12B-2511.Q4_K_M	last	3840	6.80GB	6/12	39.0s

要点：4B-Q4/Q5 并列 10/12 最优；8B 与 0.6B、harrier 同为 9/12；KaLM-12B 最低（6~7/12）且体积 3 倍。

二、聊天模型生成质量（Qwen3-Embedding-4B-Q4 / 8B-Q5 嵌入 × 5 聊天 = 10 组）

口径：可追溯=12 库内题答案带【资料N】引用；拒答=3 库外题正确拒答；忠实度=答案数字能在参考源找到的比例（弱判据）。

嵌入	聊天	可追溯	拒答	忠实度	平均耗时	token/秒
Qwen3-Embedding-8B-Q5_K_M	Qwen3-4B-Q4_K_M	12/12	3/3	100%	1.5s	210
Qwen3-Embedding-4B-Q4_K_M	Qwen3-4B-Q4_K_M	12/12	2/3	100%	1.6s	206
Qwen3-Embedding-4B-Q4_K_M	Qwen3.5-9B-Q5_K_M	12/12	3/3	100%	3.4s	117
Qwen3-Embedding-4B-Q4_K_M	Qwen3.8-27B-UD-Q5_K_M	12/12	3/3	100%	77.8s	4
Qwen3-Embedding-8B-Q5_K_M	Qwen3.8-27B-UD-Q5_K_M	12/12	3/3	100%	92.6s	3
Qwen3-Embedding-8B-Q5_K_M	Qwen3.5-9B-Q5_K_M	11/12	3/3	99%	3.3s	116
Qwen3-Embedding-8B-Q5_K_M	Qwen3-1.7B-Q4_K_M	10/12	3/3	100%	0.8s	352
Qwen3-Embedding-4B-Q4_K_M	Qwen3-1.7B-Q4_K_M	8/12	3/3	97%	0.8s	366
Qwen3-Embedding-8B-Q5_K_M	Qwen3.5-4B-Q5_K_M	6/12	3/3	100%	17.2s	181
Qwen3-Embedding-4B-Q4_K_M	Qwen3.5-4B-Q5_K_M	5/12	3/3	100%	14.1s	185

要点：可追溯满分只有 4B-Q4×{4B,9B} 与 8B-Q5×9B；3.5-4B 内容答对但常忘标引用（可追溯 5~6/12）；27B 最慢（78~93s/题）。

三、综合命中（检索 × 生成 双层，17 组实测）

口径：检索命中=锚句核心词在 top-3 块内（纯嵌入）；生成命中=核心词在最终答案内（端到端）；综合=同题双命中。补齐：9 嵌入 × Qwen3-4B-Q4 聊天（控制聊天变量），叠加 4B-Q4/8B-Q5 × 其余 4 聊天。

排名	嵌入	聊天	检索命中	生成命中	综合命中	平均耗时
1	Qwen3-Embedding-4B-Q5_K_M	Qwen3-4B-Q4_K_M	12/12	12/12	12/12	1.6s
2	Qwen3-Embedding-4B-Q4_K_M	Qwen3-4B-Q4_K_M	12/12	12/12	12/12	1.6s
3	Qwen3-Embedding-4B-Q4_K_M	Qwen3.5-9B-Q5_K_M	12/12	12/12	12/12	3.4s
4	Qwen3-Embedding-4B-Q4_K_M	Qwen3.5-4B-Q5_K_M	12/12	12/12	12/12	14.1s
5	Qwen3-Embedding-4B-Q4_K_M	Qwen3-1.7B-Q4_K_M	12/12	11/12	11/12	0.8s
6	harrier-oss-v1-0.6B-Q8_0	Qwen3-4B-Q4_K_M	11/12	11/12	11/12	1.4s
7	harrier-oss-v1-0.6B-BF16	Qwen3-4B-Q4_K_M	11/12	11/12	11/12	1.4s
8	Qwen3-Embedding-8B-Q5_K_M	Qwen3-4B-Q4_K_M	11/12	11/12	11/12	1.5s
9	bge-m3-q8_0	Qwen3-4B-Q4_K_M	11/12	11/12	11/12	1.6s
10	Qwen3-Embedding-0.6B-Q8_0	Qwen3-4B-Q4_K_M	11/12	11/12	11/12	1.8s
11	Qwen3-Embedding-8B-Q5_K_M	Qwen3.5-9B-Q5_K_M	11/12	11/12	11/12	3.3s
12	Qwen3-Embedding-4B-Q4_K_M	Qwen3.8-27B-UD-Q5_K_M	12/12	11/12	11/12	77.8s

排名	嵌入	聊天	检索命中	生成命中	综合命中	平均耗时
13	Qwen3-Embedding-8B-Q5_K_M	Qwen3.8-27B-UD-Q5_K_M	11/12	11/12	11/12	92.6s
14	Qwen3-Embedding-8B-Q5_K_M	Qwen3-1.7B-Q4_K_M	11/12	10/12	10/12	0.8s
15	KaLM-Embedding-Gemma3-12B-2511.Q5_K_M	Qwen3-4B-Q4_K_M	10/12	11/12	10/12	1.4s
16	KaLM-Embedding-Gemma3-12B-2511.Q4_K_M	Qwen3-4B-Q4_K_M	9/12	10/12	9/12	1.8s
17	Qwen3-Embedding-8B-Q5_K_M	Qwen3.5-4B-Q5_K_M	11/12	9/12	9/12	17.2s

要点：4B-Q4/Q5 嵌入是唯一 12/12（其余 11/12 且全丢 Q11"CPU 版"场景题）；KaLM-12B 垫底（9~10/12）。

四、为什么 45 组全矩阵只测了 17 组

全矩阵 = 9 嵌入 × 5 聊天 = 45 组，实测 17 组；未测的 28 组 = 其余 7 嵌入 × {1.7B, 3.5-4B, 9B, 27B}。原因不是偷懒，是控制变量法：

- 阶段 A 已证明检索与聊天无交互**：同嵌入档内换任意聊天模型，top-3 检索结果完全一致（12/12）。检索质量只由嵌入模型决定——所以 9 个嵌入只需配一个代表聊天模型（选 4B-Q4）即可排序。
- 生成质量只由聊天模型决定**：top-3 一旦包含答案块，能否答对取决于聊天模型本身——所以聊天只需在两档代表性嵌入（4B-Q4/8B-Q5）上测 5 个即可排序。
- 唯一需要担心的交互效应**（嵌入检索差 1 题 → 综合掉 1 题）已由 8B 档验证：检索 11/12 → 综合 9~11/12。
- 剩余 28 组是已测两个变量"主效应"之后的笛卡尔积冗余，增量信息 ≈ 0；成本约 4 小时（27B 两组占大半，且 27B 已淘汰）。

一句话：**主效应测全了，交互效应已被 8B 档探明**——17 组足以支撑选型。

五、推荐选型（供 README / 整合包 / 开发者文档引用）

GPU / CUDA 档（推荐）

- 聊天: **Qwen3.5-9B-Q5_K_M** (6.07GB) ——综合 12/12 + 可追溯 12/12 双满分, 3.4s/题
- 嵌入: **Qwen3-Embedding-4B-Q4_K_M** (2.33GB) ——综合 12/12, 2.33GB 三档通用

CPU 档

- 聊天: **Qwen3-4B-Q4_K_M** (2.33GB) ——综合 12/12, 1.6s/题, 206 tok/s
- 嵌入: **Qwen3-Embedding-4B-Q4_K_M** (2.33GB) 满配; **Qwen3-Embedding-0.6B-Q8_0** (0.60GB) 省内存 (综合 11/12, 丢 Q11"CPU 版"场景题)

Vulkan / 核显档

- 聊天: **Qwen3-4B-Q4_K_M** (2.33GB) ——综合 12/12, 可追溯 11/12 (比 3.5-4B 的 5/12 稳)
- 嵌入: **Qwen3-Embedding-4B-Q4_K_M** (2.33GB)

淘汰结论

- **Qwen3.8-27B**: 综合 11/12 无优势, 77.8s/题慢 20 倍——淘汰
- **KaLM-Embedding-Gemma3-12B**: 综合 9~10/12 垫底, 6.8~7.9GB 体积 3 倍——淘汰
- **Qwen3-1.7B**: 综合 11/12 但可追溯 8/12, 仅极端省内存场景考虑
- **bge-m3 / harrier / 0.6B**: 综合 11/12, 可作 CPU 嵌入平替, 但会丢"CPU 版"场景题